

Datenverarbeitung 2 | SS 2025
Hausaufgabenübung 4 | 29.04.2025
Abgabe: 06.05.2025, 16 Uhr


Hinweise zur Abgabe (bitte sorgfältig lesen!):

- Wenn nicht anders angegeben ist, wird erwartet, dass Sie die Übungsaufgaben durch das Erstellen von Python-Skripten selbstständig und vollständig lösen.
- Die Lösungen der Übungen werden in Ein- bis Zweiergruppen gemeinsam im Lernraum abgegeben. Verwenden Sie folgende Dateinamen für Ihre Lösungen: *Matrikelnummer1_Matrikelnummer2_UXX_AX.py* z.B. *333444_333555_U01_A1.py* oder *333555_U01_A1.py* für das Python-Skript für die 1. Aufgabe in Übung 01. Verwenden Sie äquivalente Namensgebungen für andere Datei-Formate, z.B.: *333555_U01_A1.pdf*.
- Verwenden Sie die Vorlagendatei im Moodle für Ihre Abgaben und stellen Sie sicher, dass sie alle geforderten Angaben (Namen, Matrikelnummern und Email Adressen der Abgebenden) enthält, damit wir Ihnen Rückmeldungen zu Ihren Übungen per E-Mail schicken können.
- Sollten Sie sich nicht an dieses vorgegebene Schema halten, werden Ihnen Punkte abgezogen.
- Die Skripte müssen mit aussagekräftigen print-Statements oder deutlich gekennzeichneten Plots eine eindeutige Zuordnung der Ergebnisse zu den jeweiligen Fragestellung ermöglichen.
- Es müssen alle verwendeten Datenfiles mit abgegeben werden, mit Ausnahme von durch uns zur Verfügung gestellten Daten. Die Skripte müssen sofort lauffähig sein. Es dürfen keine input Befehle verwendet werden.
- Die Übungen werden durch die Tutoren nach einem einheitlichen Schema benotet.
- Andere Lösungen der Übungsaufgaben, z.B. mit iPython-Notebooks oder mit MAPLE, MATLAB, MATHEMATICA, ... können wir nicht akzeptieren.

Aufgabe 1. (t-Test zweier Notenspiegel)

In einer aktuellen Studie wurde untersucht, ob es einen signifikanten Unterschied in den Klausurergebnissen der Höheren Mathematik zwischen Lehramts-Studierenden und Physik-Studierenden gibt. Die Ergebnisse beider Gruppen wurden gesammelt, um zu prüfen, ob die erreichten Punktzahlen statistisch signifikant voneinander abweichen. Die Studie führt den t-Test durch mit einem Signifikanzniveau von $\alpha = 0,05$ und kommt zu dem Schluss:

Lehramts-Studierende und Physik-Studierende sind im Durchschnitt gleich gut.



Wir wollen beurteilen, ob die Studie insgesamt die korrekte Methode verwendet hat.

- a) Unter Betrachtung des gegebenen Notenspiegels: Welche Voraussetzungen für den t -Test sind hier vermutlich nicht erfüllt? Reichen Sie Ihre Antwort in einem kurzen print()-Statement ein.

[1 Punkt]

- b) Überprüfen Sie numerisch, ob diese Voraussetzungen gelten. Ist es hier korrekt, den t-Test anzuwenden? Begründen Sie Ihre Antwort mit Hilfe der in `lehramtNoten.csv` gegebenen Daten.

Hinweis: Wenden Sie den χ^2 -Test an. Hier können Sie annehmen, dass beide Verteilungen eine Standardabweichung von 1 haben.

[2 Punkte]

- c) Erzeugen Sie außerdem einen aussagekräftigen Plot, der die Voraussetzung und die mit der tatsächlichen Datenlage vergleicht.

[1 Punkt]

Hinweis: Die Notenspiegel sind keiner realen Klausur entnommen.

5 Punkte

Aufgabe 2. (t-Test II)

Stellen Sie sich vor, Sie sind ein Wissenschaftler, der die Wirkung eines neuen Medikaments auf die Entzündungswerte von Patienten untersuchen möchte. Dazu haben Sie zwei Probandengruppen von Patienten gebildet. Eine Gruppe erhält das neue Medikament, die andere Gruppe erhält ein Placebo. Die Entzündungswerte werden vor und nach der Behandlung gemessen. Sie möchten nun herausfinden, ob das Medikament signifikant niedrigere Entzündungswerte im Vergleich zum Placebo verursacht:

- Gruppe A: Patienten, die das neue Medikament erhalten haben.
- Gruppe B: Patienten, die ein Placebo erhalten haben.

Die Entzündungswerte (in mg/L) nach der Behandlung sind in der Datei `blutwerte.csv` gespeichert.

- a) Diskutieren Sie, ob Sie hier einen t-Test anwenden dürfen. Plotten Sie dazu die Entzündungswerte beider Gruppen in einem gemeinsamen Histogramm. Passen Sie je eine Normalverteilung an die Histogramme an, stellen Sie die Anpassung grafisch dar. Nehmen Sie dazu ausnahmsweise keine Fehler auf die Messdaten an. Kommentieren Sie, ob die gemessenen Daten mit den Modellen übereinstimmen. Hinweis: `.dropna()` kann hilfreich sein, wenn Sie `pandas` zum Einlesen der Daten verwenden.

[2 Punkte]

In der Vorlesung wurde die Formel der Teststatistik t für zwei gleichgroße Stichproben mit unbekanntem σ der zugrundeliegenden Verteilung eingeführt. Die allgemeine Formel für zwei ungleichgroße Stichproben mit unbekanntem σ lautet

$$t = \frac{\bar{x}_1 - \bar{x}_2}{S \sqrt{1/N_1 + 1/N_2}} \quad \text{mit} \quad S^2 = \frac{(N_1 - 1)s_1^2 + (N_2 - 1)s_2^2}{N_1 + N_2 - 2}. \quad (1)$$

- b) Leiten Sie die Ihnen bekannte Formel aus der Vorlesung aus Gleichung (1) her. Geben Sie Ihre Lösung als `.pdf` und `.tex` Datei in der üblichen Datei-Benennung ab.

[1 Punkt]

Führen Sie nun einen unabhängigen t-Test durch, um zu prüfen, ob das Medikament signifikant niedrigere Entzündungswerte im Vergleich zum Placebo verursacht (das Schwellenniveau zum Ablehnen der Testhypothese liegt bei $\alpha_C = 0.05$):

- c) Erklären Sie qualitativ, was der t-Test im Kontext dieser Aufgabe testet.
[1 Punkt]
- d) Führen Sie den t-Test durch und berechnen Sie das beobachtete Signifikanzniveau.
[2 Punkte]
- e) Vergleichen Sie das beobachtete Signifikanzniveau mit dem Schwellniveau α_C und ziehen Sie eine Schlussfolgerungen über die Wirksamkeit des Medikaments.
[1 Punkt]
- f) Mit welcher Wahrscheinlichkeit sind die Unterschiede in den Entzündungswerten zufällig entstanden?
[1 Punkt]

9 Punkte**Aufgabe 3. (Optimierung der Handy-Produktion)**

Eine Firma stellt Displays her und baut sie direkt in neue Handys ein. Ein Anteil von 5% der produzierten Displays ist defekt.

Eine Messung ergibt einen Parameter t , dieser ist für heile Displays und kaputte Displays Gauß-Verteilt um zwei verschiedene $\mu_{\text{intakt}} = 10$, $\mu_{\text{defekt}} = 5$ und $\sigma_{\text{intakt}} = 1$, $\sigma_{\text{defekt}} = 2.5$. Jedes Display wird dieser Messung unterzogen. Für Werte t unter einem bestimmten Grenzwert t_c werden Displays verworfen.

- a) Stellen Sie die Verteilungen von t für intakte und defekte Displays graphisch dar. Berechnen Sie für den Grenzwert $t_c = 8.5$ die Wahrscheinlichkeiten α/β für einen falsch-positiven/negativen Test (hier: positiv=defekt, negativ=intakt). Stellen sie diese Wahrscheinlichkeiten und den Grenzwert zusätzlich an den vorherigen Graphen dar. Sie können dafür zB. `matplotlib.pyplot.fill_between` verwenden. Berechnen Sie außerdem die Wahrscheinlichkeit, dass ein verworfenes Handy auch tatsächlich defekt ist.
[3 Punkte]
- b) Stellen Sie die Wahrscheinlichkeit für ein echt-positives Ergebnis in Abhängigkeit der Wahrscheinlichkeit für ein falsch-positives Ergebnis im Bereich $[0, 1]$ dar.
[1 Punkt]
- c) Der Verkauf eines intakten Handys erzielt einen Gewinn von 200€, ein defektes verkaufte Handy bedeutet einen Verlust von 1000€. Ein Display zu verwerfen ist in jedem Fall ein Verlust von 50€. Stellen Sie den zu erwartenden Gewinn pro produziertem Handy in Abhängigkeit von t_c graphisch dar und bestimmen Sie den idealen Wert t_c für den der zu erwartende Gewinn maximal wird.
[1 Punkt]
- d) Überprüfen Sie das vorherige Ergebnis mit einer Monte-Carlo Simulation, in dem Sie für eine ausreichend große Stichprobe an N Handys und verschiedene t_c den Gewinn berechnen. Wiederholen Sie die Stichprobe jeweils M mal, um eine Unsicherheit auf den zu erwartenden Gewinn zu berechnen. Stellen Sie das Ergebnis mit Unsicherheiten graphisch dar.
[2 Punkte]

7 Punkte